N.º 1: Datos, Información, Toma de Decisiones, Fuentes y Formatos

Aprendices

Angel Andres Soto Romero

Juan Angel Rios Lopez

Julieth Nathalia Suarez Daza

Ficha: 3602991

Instructora

Nathalia Martinez Vargas

Servicio Nacional de Aprendizaje

Procesamiento de Datos Para Modelos de Inteligencia Artificial

Trimestre I

Centro de Materiales y Ensayos

06 de noviembre de 2026

Bogotá D.C.

Tabla de contenido

Introducción 5

Actividades 6

2.1.1 Actividades a Desarrollar 6

2.2 Actividades de contextualización e identificación de conocimientos. 11

2.3 Actividades de Apropiación del Conocimiento 14

2.4 Actividades de Transferencia de Conocimiento 22

2.4.1 Desarrollo del Diccionario de Datos 22

Conclusiones 26

Referencias Bibliográficas 27

Listado de Ilustraciones

Ilustración 1 Esquema conceptual ilustración tablero de control..... 8

Ilustración 2 *Error Ejemplo 1 Employee Pay Equity Dataset*..... 15

Ilustración 3 *Error Ejemplo 2 Employee Pay Equity Dataset*..... 17

Ilustración 4 *Error Ejemplo 3 Employee Pay Equity Dataset*..... 18

Ilustración 5 *Error Ejemplo 4 Employee Pay Equity Dataset*..... 19

Ilustración 6 *Error Ejemplo 5 Estados Financieros NIIF-*..... 21

Ilustración 7 *Estados Financieros NIIF- Estado de Resultado Integral*..... 22

Listado de Tablas

Tabla 1 *Capacidad de formatos.CSV, XLS, XSLX* 6

Tabla 2 *Identificación y Clasificación de las Variables de los Conjuntos de Datos.* 12

Tabla 3 *Diccionario de Datos* 24

Introducción

En la guía se trabajan diferentes temas relacionados con los datos y la importancia que tienen en el manejo de la información. Durante las actividades se busca aprender a identificar los diferentes formatos de archivos, conocer de dónde se pueden obtener los datos y entender por qué es importante que la información esté organizada y no tenga errores.

A lo largo del trabajo realizamos varias actividades, comenzando por conocer las diferencias entre los formatos CSV, XLS y XLSX. También exploramos diferentes plataformas donde se pueden encontrar conjuntos de datos y trabajamos con información relacionada con la desigualdad de género, los salarios y los estados financieros. A partir de estos datos, realizamos una revisión para encontrar algunos errores, como información repetida, espacios vacíos y diferentes formas de escribir los mismos datos.

Con el desarrollo de esta guía buscamos aprender y familiarizarnos con algunos de los procesos que se utilizan para trabajar con datos, desde su búsqueda y clasificación hasta su revisión y organización. Estos conocimientos son importantes para nuestra formación en el programa de Procesamiento de Datos para Modelos de Inteligencia Artificial, ya que nos permiten comprender mejor cómo se debe preparar la información antes de utilizarla en diferentes análisis o proyectos.

Actividades

2.1.1Actividades a Desarrollar

1.Documentar de manera concisa las diferencias estructurales entre un archivo de texto plano (CSV), un formato de hoja de cálculo heredado (XLS) y uno moderno (XLSX), haciendo énfasis en sus límites de almacenamiento (filas y columnas) e identificando en que punto exacto fallo la integridad de los datos en el caso expuesto.

En la siguiente tabla se especifica las diferencias puntuales entre cada formato: (CSV, XLS, XLSX)

Tabla 1

Capacidad de formatos.CSV, XLS, XSLX

Formato	**.CSV**	**.XLS**	**.XLSX**
Tipo de Archivo	Texto plano	Hoja de Cálculo Binaria	Hoja de Cálculo basada en XML
Máximo de Filas	Sin límite inherente al formato	65.536	1.048.576
Máximo de columnas	Sin límite inherente al formato	256	16.348
Organización	Registros y campos separados por comas	Libros, hojas, filas, columnas y celdas	Libros, hojas, filas, columnas y celdas
Características Adicionales	No almacena características propias de Excel	Formatos y funcionalidades en versiones antiguas	Fórmulas, estilos y funciones modernas.

Nota: Fuente: Elaboración propia. Los límites de CSV dependen de las herramientas y recursos utilizados para cargarlo. En cambio, los límites de XLS y XLSX corresponden a Microsoft Excel.

Representación visual y estructura interna de los datos

CSV distribuye los datos en campos que se separan por comas. Un registro está compuesto por una serie de campos que representan una observación. Algunos archivos incluyen encabezados, cuyos campos permiten identificar el contenido de cada columna (Shafranovich 2005; Government Digital Service & Central Digital and Data Office, 2021).

Por otro lado, Microsoft Excel muestra al usuario una interfaz gráfica de hoja de cálculo que organiza los datos en: hojas, tablas, filas, columnas y celdas. Sin embargo, la manera en que internamente expresan los datos y los almacena varía según el formato que utilizan:

En el caso de XLS utiliza el formato BIFF8 (Binary Interchange File Format 8) que expresa los datos en secuencias binarias que son organizadas por registros, cada registro cuenta con la siguiente información: un identificador o tipo de registro, longitud del registro en bytes, datos correspondientes al registro (Microsoft, s. f.-b).

En cambio, XLSX utiliza un lenguaje de marcado XML (Extensible Markup Language) que estructura los datos mediante: elementos, atributos y valores. Asimismo, el archivo puede contener componentes XML e información adicional relacionada con propiedades de presentación, estilos, colores fuentes. Dicho contenido es agrupado y comprimido en un paquete ZIP que contiene los componentes del archivo XLSX (Microsoft s. f.-b; Microsoft, 2025).

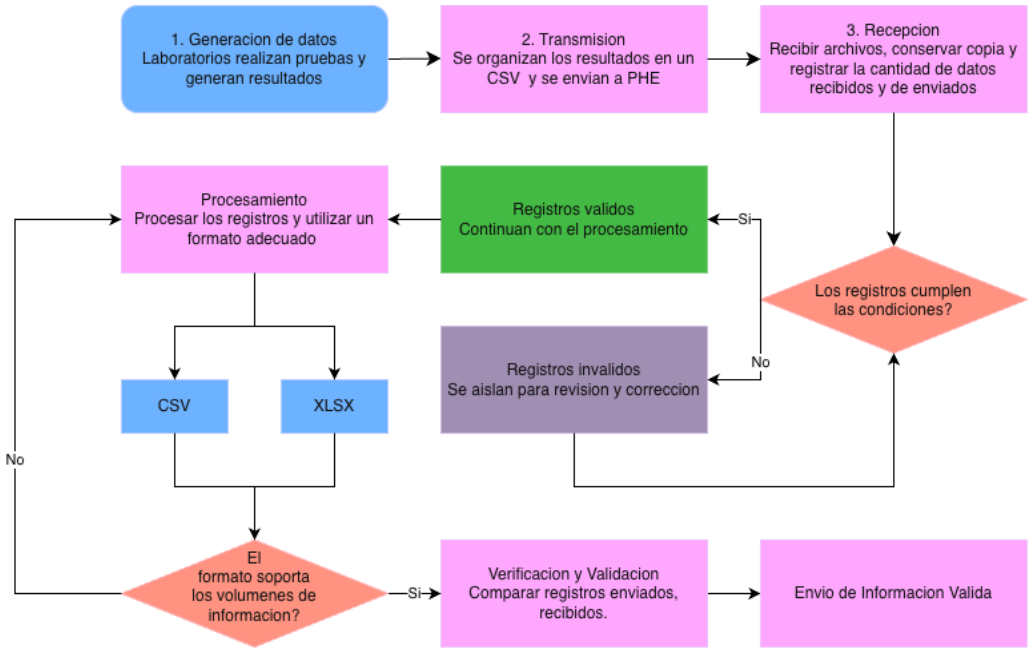
Esta diferencia entre los formatos permite comprender el fallo presentado en el caso de estudio. Durante la importación de los archivos CSV a las plantillas XLS, los registros que superaron el máximo de filas que contiene este último, como se específica en la tabla, fueron

excluidos. Como consecuencia 15.841 casos positivos no fueron tomados en cuenta en los análisis del sistema central, además de que no se generó ninguna alerta que notificara esta pérdida de información (Ing. Natalia Martínez Vargas, 2026).

2. Elaborar un esquema conceptual que ilustre como debió ser el transito seguro de la inforamcion desde los laboratorios (origen) has el tablero de control gubernamental (destino). Se debe de justificar que formatos (CSV o XLSX) debieron empleasrse en cada etapa para garantizar la preservacion de los casi 16.000 registros perdidos.

Ilustración 1

Esquema conceptual ilustración tablero de control



Nota. Elaboración propia con base en información extraída de la guía Ing. Nathalia Martinez Vargas (2026).

El uso de CSV o XLSX, junto con controles adecuados de validación y verificación, habría sido una alternativa más apropiada para recibir y procesar los datos del caso. Ambos formatos ofrecen ventajas frente a XLS para manejar los volúmenes de información, sin

embargo, la elección del formato por sí sola no garantiza la integridad de los registros, por tal razón nuestro grupo se encargó de agregar otras consideraciones que facilitarían este proceso:

1.El caso expuesto no especifica si se conservaban copias del archivo original antes de su importación a una plantilla XLS. Aun así, se recomienda esta práctica como medida preventiva en caso de perder parte de la información del archivo original o en su defecto que los datos fueran alterados.

2.Validación de calidad: Los datos deben pasar por un proceso de validación de calidad que revise sus condiciones como la estructura y columnas, los tipos de datos, campos obligatorios, la validez de sus valores y si sus registros presentan duplicados o inconsistentes. De esta manera, se permite el flujo de los datos que cumplan los criterios establecidos, mientras que aquellos que no cumplan se conservan para su revisión y corrección, de tal manera que siga circulando la información y no sea bloqueada solamente por unos pocos registros.

3.Validación de integridad: Se propone implementar un conteo de la cantidad de registros del archivo original y compararla con la cantidad de registros obtenidos del archivo procesado. De esta manera, se puede verificar que el resultado contenga la cantidad de registros esperados. Además, hay que comparar los registros obtenidos con los originales para detectar posibles pérdidas o alteraciones de la información.

4.Como ya mencionamos, la elección de un formato diferente no es suficiente para asegurar que se conserve la integridad de los datos. Por esta razón, debe comprobarse que el sistema tenga la capacidad necesaria para recibir y procesar los volúmenes de información. En caso de que se presente algún fallo debe implementarse mecanismos de alerta, revisión y recuperación de los registros, así como coordinar entre los laboratorios comerciales y el sistema central las medidas requeridas para la transferencia y procesamiento exitoso de la información.

3.Redactar una conclusión analítica sobre la relación directa entre el conocimiento técnico del analista de datos y la responsabilidad ética en la toma de decisiones a nivel gerencial o gubernamental.

3.1 Conclusión

La elección de un formato más adecuado no es suficiente para conservar la integridad de los datos. Esta medida en conjunto de otras prácticas como las ya sugeridas anteriormente podrían haber ayudado a reducir los riesgos durante el procesamiento hasta cierto punto, pues los sistemas no siempre van a estar totalmente preparados para enfrentar estos fallos o las personas que diseñan y gestionan pueden no prever las diferentes situaciones adversas que se puedan presentar. Lo que pueden hacer es que en estas situaciones cuenten con mecanismos de alerta y notificación junto con especialistas con conocimientos técnicos sobre las capacidades y limitaciones de los sistemas y herramientas, de esta manera se podrá detectar problemas y actuar oportunamente. Esto facilitara la coordinación de los grupos involucrados para implementar soluciones adecuadas y reducir el riesgo de errores que tengan consecuencias más críticas, sobre todo si la información influye en las decisiones relacionadas con la salud pública.

Por último, no quisiéramos atribuir culpas injustificadas a los actores involucrados, sin embargo consideramos que debe analizarse la responsabilidad de quienes implementan, supervisan y utilizaban los sistemas encargados de recibir y procesar la información adecuadamente. Pues el conocimiento técnico de estos profesionales conlleva una responsabilidad ética, ya que estos deben encargarse de que los datos sean confiables y deben advertir de los posibles errores o limitaciones que puedan afectar las decisiones gerenciales o gubernamentales.

2.2 Actividades de contextualización e identificación de conocimientos.

Cada equipo de trabajo deberá escoger una temática que quiera estudiar y elaborar una bitácora de exploración y clasificación de datos, debe contener la siguiente estructura:

Enunciado del eje temático concertado por el equipo y una breve justificación de su elección.

Un Párrafo argumentativo donde el equipo clasifique y justifique si los conjuntos de datos que van a utilizar corresponden a fuentes de extracción primarias o secundarias.

Un listado de al tres (3) conjuntos de datos descubiertos durante la exploración en los portales (Kaggle, OpendML, Datos Abiertos Bogotá Y Datos Abiertos Colombia) (Datos Abiertos Bogotá, s. f.; Datos Abiertos Colombia, s. f.; Kaggle, s. f.Open ML, s. f.), especificando para cada uno: nombre del dataset, portal de alojamiento y enlace (URL) de acceso.

Una tabla estructurada que extraiga un mínimo de treinta (30) variables o columnas observadas durante la exploración de los datasets seleccionados, en la cual se clasifique rigurosamente cada variable en su respectiva categoría estadística (Cualitativa: nominal u ordinal; Cuantitativa: discreta o continua)

Se seleccionó esta temática porque permite explorar diferentes aspectos relacionados con las desigualdades de género, las diferencias salariales y las condiciones económicas de las organizaciones.

En este sentido, consideramos que es un tema de interés social y económico, ya que permite identificar situaciones que afectan tanto a las personas como a las empresas. Asimismo, mediante el análisis de conjuntos de datos, podemos reconocer patrones, comparar información y obtener conocimientos que contribuyan a comprender mejor estas problemáticas.

Por otra parte, los tres conjuntos de datos seleccionados corresponden a fuentes de información secundarias, debido a que fueron publicados previamente en plataformas de consulta y descarga de datos, y no fueron recolectados directamente por el equipo.

Finalmente, durante la exploración de los portales de datos abiertos y Kaggle, se identificaron los siguientes tres conjuntos de datos de interés:

Nombre data set: Gender Inequality Index by Country

Portal de alojamiento: Kaggle

URL:https://www.kaggle.com/datasets/iamsouravbanerjee/gender-inequality-index-dataset?utm_source=chatgpt.com

Nombre data set: Employee Pay Equity Dataset

Portal de alojamiento: Kaggle

URL: https://www.kaggle.com/datasets/terencekatua/employee-pay-equity-dataset

Nombre dataset: Estados Financieros NIIF- Estado de Resultado Integral

Portal de alojamiento: Datos abiertos Colombia

URL: https://www.datos.gov.co/d/prwj-nzxa?utm_source=chatgpt.com

Tabla 2

Identificación y Clasificación de las Variables de los Conjuntos de Datos.

Data set	**Variables**	**Categoría**	**Subcategoría**
Gender Inequalitty Index	ISO3	Cualitativo	Nominal
Gender Inequalitty Index	Country	Cualitativo	Nominal
Gender Inequalitty Index	Continent	Cualitativo	Nominal

Data set	Variables	Categoría	Subcategoría
Gender Inequalitty Index	Hemisphere	Cualiativo	Nominal
Gender Inequalitty Index	Human Development Groups	Cualiativo	Ordinal
Gender Inequalitty Index	UNDP Developing Regions	Cualiativo	Nominal
Gender Inequalitty Index	HDI Rank (2021)	Cuantitativo	Discreto
Gender Inequalitty Index	GII Rank (2021)	Cuantitativo	Discreto
Gender Inequalitty Index	Gender Inequality Index (1990)	Cuantitativo	Continuo
Gender Inequalitty Index	Gender Inequality Index (1991)	Cuantitativos	Continuo
Employee pay equity dataset	Employee_id	Cualitativo	Nominal
Employee pay equity dataset	Full_name	Cualitativo	Nominal
Employee pay equity dataset	Source_dataset	Cualitativo	Nominal
Employee pay equity dataset	Age	Cuantitativo	Discreto
Employee pay equity dataset	Gender	Cualitativo	Nominal
Employee pay equity dataset	Ethnicity	Cualitativo	Nominal
Employee pay equity dataset	Education_level	Cualitativo	Ordinal
Employee pay equity dataset	Years_experience	Cuantitativo	Discreto
Employee pay equity dataset	Tenure_years	Cuantitativo	Discreto

Data set	Variables	Categoría	Subcategoría
Employee pay equity dataset	Department	Cualitativo	Nominal
Estados financieros NIFF	Codigo Instancia	Cualitativo	Nominal
Estados financieros NIFF	Nit	Cualitativo	Nominal
Estados financieros NIFF	Numero radicado	Cualitativo	Nominal
Estados financieros NIFF	Id Punto Entrada	Cualitativo	Nominal
Estados financieros NIFF	Punto Entrada	Cualitativo	Nominal
Estados financieros NIFF	Id Taxonomia	Cualitativo	Nominal
Estados financieros NIFF	Taxonomia	Cualitativo	Nominal
Estados financieros NIFF	Fecha de corte	Cuantitativo	Discreto
Estados financieros NIFF	Concepto	Cualitativo	Nominal
Estados financieros NIFF	Periodo	Cuantitativo	Discreto

Nota. Fuente: Elaboración propia con base en la información extraída de los conjuntos de datos utilizados durante el proceso de exploración y clasificación de variables.

2.3 Actividades de Apropiación del Conocimiento

Con base en la temática concertada previamente, cada equipo seleccionará y descargará dos (2) datasets reales (obligatoriamente uno en formato CSV y otro en formato XLSX) alojados en los portales explorados. A continuación, ejecutaré una auditoría técnica rigurosa sobre ambos

archivos para descubrir y documentar por lo menos seis (6) inconsistencias en los datos. Para la explicación de los problemas encontrados use la siguiente estructura:

¿Que o cual es problema?

¿Como se ha detectado?

¿Por qué cree que se trata de un problema?

¿Un ejemplo completo extraído del propio dataset?

Ejemplo 1.

1. ¿Qué o cuál es el problema?

En la variable full_name se identificaron inconsistencias en la estandarización de los nombres completos, debido a que algunos registros incluyen abreviaturas y títulos de cortesía junto con los nombres y apellidos.

2. ¿Cómo se ha detectado?

Se detectó por medio de la visualización de los registros de la variable full_name en la cual se observaron diferentes formas de escritura de los nombres y apellidos.

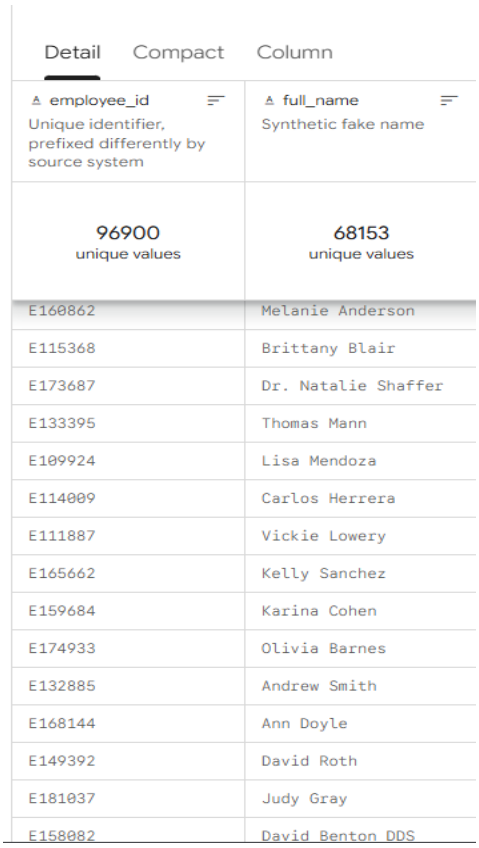
3. ¿Por qué cree que se trata de un problema?

Puede ser un problema en procesos posteriores como análisis y procesamiento. Ya que los datos deben mantener un formato estandarizado y uniforme, para así facilitar la lectura, organización y comparación de la información.

4. ¿Un ejemplo completo extraído del propio dataset?

Ilustración 2

Error Ejemplo 1 Employee Pay Equity Dataset



Detail Compact Column

employee_id Unique identifier, prefixed differently by source system	full_name Synthetic fake name
96900 unique values	68153 unique values
E160862	Melanie Anderson
E115368	Brittany Blair
E173687	Dr. Natalie Shaffer
E133395	Thomas Mann
E109924	Lisa Mendoza
E114009	Carlos Herrera
E111887	Vickie Lowery
E165662	Kelly Sanchez
E159684	Karina Cohen
E174933	Olivia Barnes
E132885	Andrew Smith
E168144	Ann Doyle
E149392	David Roth
E181037	Judy Gray
E158082	David Benton DDS

Nota. Fuente: Captura de pantalla tomada de *Employee Pay Equity Dataset from Kaggle (2026).*

Ejemplo 2.

1. ¿Qué o cuál es el problema?

En la variable gender se identificaron inconsistencias en los valores registrados, debido a que se utilizan diferentes denominaciones para representar el género, como abreviaturas, palabras completas, variaciones entre minúsculas y mayúsculas e incluso registros que no corresponden a esa categoría.

2. ¿Cómo se ha detectado?

Se detectó mediante la revisión de los valores de la variable gender, en la cual se encontraron registros como, Female, FEMALE, F, Woman, Male, Man, M, NB, non-binary, Other y otros valores.

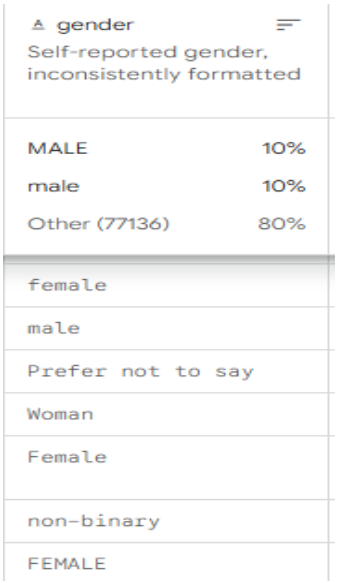
3. ¿Por qué cree que se trata de un problema?

Se considera un problema porque la variable debe mantener criterios uniformes para registrar la información, la existencia de diferentes denominaciones, abreviaturas y valores incorrectos dificultan la clasificación de los datos.

4. ¿Un ejemplo completo extraído del propio dataset?

Ilustración 3

Error Ejemplo 2 Employee Pay Equity Dataset



Nota. Fuente: Captura de pantalla tomada de *Employee Pay Equity Dataset from Kaggle (2026).*

Ejemplo 3.

etnicity

1. ¿Qué o cuál es el problema?

La columna presenta campos vacios

2. ¿Cómo se ha detectado?

Por Observacion

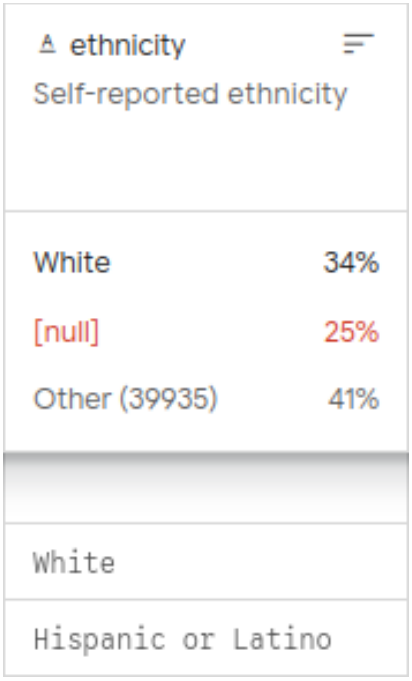
3.¿Por qué cree que se trata de un problema?

Un campo vacío, puede ser un error porque representa falta de información que puede ser necesaria para procesos posteriores como análisis.

4.¿Un ejemplo completo extraído del propio dataset?

Ilustración 4

Error Ejemplo 3 Employee Pay Equity Dataset



Nota. Fuente: Captura de pantalla tomada de *Employee Pay Equity Dataset from Kaggle (2026).*

Ejemplo 4.

Education level

1. ¿Qué o cuál es el problema?

La falta de una estructura clara en la presentación de los datos en la columna. Por ejemplo: el orden del nombre, abreviaciones del nombre y el uso desigual de mayúsculas y minúsculas entre los diferentes datos.

2. ¿Cómo se ha detectado?

Por Observación

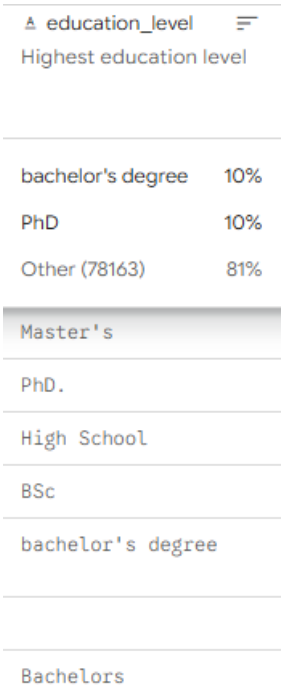
3. ¿Por qué cree que se trata de un problema?

La falta de coordinación de una estructura clara en los datos puede representar problemas de interpretación, lectura y de procesamiento.

4. ¿Un ejemplo completo extraído del propio dataset?

Ilustración 5

Error Ejemplo 4 Employee Pay Equity Dataset



Nota. Fuente: Captura de pantalla tomada de *Employee Pay Equity Dataset from Kaggle (2026).*

Ejemplo 5.

1. ¿Qué o cuál es el problema?

El problema identificado es la inconsistencia en los valores registrados en la columna «periodo», debido a que se utilizan diferentes formatos y criterios para representar la información temporal.

Por ejemplo, en una misma columna aparecen valores expresados como años numéricos (2015, 2017, 2018), descripciones relativas al tiempo («periodo actual», «periodo anterior») y formatos que incluyen una subdivisión, como «2015-2».

Esto evidencia una falta de uniformidad en la estructura y representación de los datos.

2. ¿Cómo se ha detectado?

El problema se ha detectado mediante la revisión y exploración de los valores únicos de la columna «periodo», identificando que existen registros con diferentes estructuras y convenciones de escritura.

Al comparar los valores, se observa que algunos corresponden a años específicos, otros a referencias temporales relativas y otros parecen representar periodos subdivididos.

3. ¿Por qué cree que se trata de un problema?

Se considera un problema porque la falta de estandarización puede generar dificultades en el procesamiento, análisis e interpretación de los datos.

En particular:

Puede dificultar la ordenación cronológica de los registros.

Puede generar errores al realizar agrupaciones y comparaciones por periodo.

Puede afectar la elaboración de estadísticas y visualizaciones temporales.

Puede provocar interpretaciones incorrectas, ya que no queda claro si «periodo actual» y «periodo anterior» hacen referencia a años concretos o a intervalos temporales diferentes.

Puede generar problemas en procesos de análisis automatizados que esperan un formato homogéneo.

4. ¿Un ejemplo completo extraído del propio dataset?

Ilustración 6

Error Ejemplo 5 Estados Financieros NIIF-

PERIODO
2015
Periodo Anterior
Periodo Actual
2014
2014

Nota. Fuente: Captura de pantalla tomada de Estados Financieros NIIF de Datos Colombia (2026).

Ejemplo 6.

1. ¿Qué o cuál es el problema?

Se identifica un problema de duplicidad de datos en la columna CODIGO_INSTANCIA, debido a que un mismo código aparece registrado múltiples veces dentro del dataset. Por ejemplo, el código 106.819 aparece cuatro veces, lo que evidencia una posible repetición de registros que debería ser revisada.

2. ¿Cómo se ha detectado?

El problema se detectó mediante una inspección visual de los valores de la columna CODIGO_INSTANCIA, en la cual se identificaron códigos repetidos. Posteriormente, se puede confirmar mediante herramientas de análisis de datos, como la función de formato condicional o la opción de eliminación de duplicados de Excel,

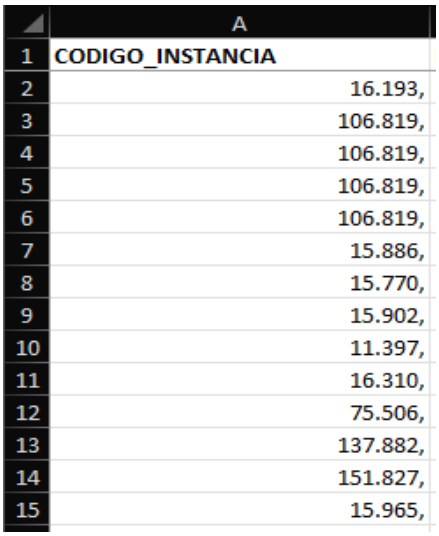
3. ¿Por qué cree que se trata de un problema?

Se considera un problema porque, si CODIGO_INSTANCIA corresponde a un identificador único, cada registro debería tener un código diferente. La repetición de estos valores puede generar inconsistencias en la información, afectar los conteos de registros, producir resultados estadísticos incorrectos y dificultar la trazabilidad de los datos.

4. ¿Un ejemplo completo extraído del propio dataset?

Ilustración 7

Estados Financieros NIIF- Estado de Resultado Integral



	A
1	CODIGO_INSTANCIA
2	16.193,
3	106.819,
4	106.819,
5	106.819,
6	106.819,
7	15.886,
8	15.770,
9	15.902,
10	11.397,
11	16.310,
12	75.506,
13	137.882,
14	151.827,
15	15.965,

Nota. Fuente: Captura de pantalla tomada de Estados Financieros NIIF de Datos Colombia (2026).

2.4 Actividades de Transferencia de Conocimiento

El equipo de trabajo seleccionará el dataset que consideren más robusto de los dos auditados en la fase anterior. Utilizando la información contenida en dicho archivo, procederán a documentar técnicamente la estructura completa del archivo mediante un instrumento de metadatos (Diccionario de datos).

2.4.1 Desarrollo del Diccionario de Datos

Para cada variable (columna) del dataset principal seleccionado, el equipo construirá una matriz registrando rigurosamente:

1. Nombre original de la variable: (Tal cual aparece en el archivo fuente)

2. Nombre estandarizado sugerido: Propuesta de nombre técnico sin espacios, sin tildes y en minúsculas por ejemplo (promedio nota).

3. Clasificación estadística: Cualitativa (nominal/ordinal) o Cuantitativa (discreta/continua).

4. Tipo de dato técnico: Cadena de texto, numérico entero, numérico decimal, fecha, booleano, arreglo o colección, null.

5. Descripción semántica: Explicación precisa de qué representa esa columna o atributo en el contexto de su temática.

6. Unidad de medida o formato: (ej. COP, metros, porcentaje, formato DD/MM/A

Tabla 3

Diccionario de Datos

Nombre Inicial	Nombre Estantadizado	Clasificacion Estadistica	Dato Tecnico	Descripcion Semantica	Formato
ISO3	territory_serial	Cualitativo Nominal	Cadena de texto	Referencia del nombre del país apartir de 3 letras del país.	texto
Country	country	Cualitativo Nominal	Cadena de texto	El nombre del pais	texto
Continent	contitent	Cualitativo Nominal	Cadena de Texto	El continente al que pertenece el pais	texto
Hemisphere	hemisphere	Cualitativo Nominal	Cadena de texto	La posición en el hemisferio: (Northern, Sourthern)	texto
Human Development Groups	development_level	Cualitativo Nominal	Fórmulas, estilos y funciones modernas.	Clasifica los países en diferentes grupos según su nivel de desarrollo humano: (Very High, High, Medium, Low)	texto
UNDP Developing Regions	region_location	Cualitativo Nominal	Cadena de Texto	Identifica a que región del mundo pertenece cada país según el United Nations Development Programme (PNUD). Sus categorías son: (SSA, LAC, EAP, AS, ECA, SA)	texto
HDI Rank (2021)	ind_hum_dev_2021	Cuantitativo Discreto	Numérico Entero	Indicador del desarrollo humano correspondiente a el 2021	Numérico

GII Rank (2021)	ind_gen_ineq_2021	Cuantitativo Discreto	Numérico Entero	Indicador de la desigualdad en el periodo correspondiente a el 2021	Numérico
Gender Inequality Index 1990	ind_gen_ineq_1990_2021	Cuantitativo Continuo	Numérico Decimal	Indicador de desigualdad de género entre el periodo de 1990 hasta el 2021	Numérico
Gender Inequality Index 1991	ind_gen_ineq_1991	Cuantitativo Continuo	Numerico Decimal	Indicador de desigualdad de género correspondiente al periodo 1991	Numérico

Nota. Fuente: Elaboracion Propia en base al dataset Gender Inequality Index by Country Kaggle (2026)

Conclusiones

Con el desarrollo de esta guía pudimos aprender un poco más sobre la importancia de los datos y el cuidado que se debe tener al momento de trabajar con ellos. Antes de realizar las actividades, algunos de estos conceptos no eran tan claros para nosotros, pero mediante los ejercicios logramos comprender mejor las diferencias entre los formatos de archivos, los tipos de datos y la importancia de mantener la información organizada.

Uno de los aspectos que más nos llamó la atención fue encontrar errores dentro de los conjuntos de datos que seleccionamos. Pudimos observar que algo tan sencillo como dejar una casilla vacía, escribir una palabra de diferentes maneras o repetir un registro puede generar dificultades cuando se quiere analizar la información. Esto nos permitió entender que no se trata solamente de descargar datos y utilizarlos, sino que primero debemos revisarlos y comprobar que estén en buenas condiciones.

En general, consideramos que estas actividades fueron importantes para comenzar a desarrollar conocimientos sobre el procesamiento de datos. Aunque todavía tenemos mucho por aprender sobre el tema, logramos familiarizarnos con algunas herramientas, plataformas y conceptos que serán útiles durante nuestra formación en el SENA. También comprendimos que trabajar con información organizada y confiable es un paso importante para poder obtener buenos resultados en futuros proyectos relacionados con la inteligencia artificial.

Referencias Bibliográficas

Broadcom. (s. f.). *What is the maximum size of a CSV file that an Adapter can read?* https://knowledge.broadcom.com/external/article/22585/what-is-the-maximum-size-of-a-csv-file-t.html

Government Digital Service & Central Digital and Data Office. (2021, 12 de marzo). *Using CSV file format*. GOV.UK. https://www.gov.uk/guidance/using-csv-file-format

Microsoft. (s. f.-a). *Excel specifications and limits*. Microsoft Support. https://support.microsoft.com/es-es/excel/excel-specifications-and-limits

Microsoft. (s. f.-b). *File formats that are supported in Excel*. Microsoft Support. https://support.microsoft.com/es-es/excel/file-formats-that-are-supported-in-excel

Microsoft. (s. f.-c). *Worksheet compatibility issues*. Microsoft Support. https://support.microsoft.com/es-es/excel/worksheet-compatibility-issues

Shafranovich, Y. (2005, octubre). *Common format and MIME type for comma-separated values (CSV) files* (RFC 4180). RFC Editor. https://doi.org/10.17487/RFC4180